Universidad de Cundinamarca

Facultad de Ingeniería

Minería de Datos

Informe Técnico — Etapa 6

Conocimiento oculto: modelos supervisados, clustering y análisis de comentarios de YouTube

Estudiante: David Santiago Romero

dsantiagoromero@ucundinamarca.edu.co

Docente: Édison Gustavo Cañón Varela

Proyecto: Migración y Desplazamiento Humano (trabajo individual)

Repositorio: https://github.com/DROMEROH14/migracion-desplazamiento-humano

Aplicación: https://dromeroh14.pythonanywhere.com/conocimiento-oculto

Video de sustentación: [ENLACE DEL VIDEO PENDIENTE: se agrega al publicarlo]

Noviembre 13 de 2026

1. Contexto y objetivo

El proyecto estudia el **desplazamiento forzado** por conflicto, violencia y desastres, a nivel mundial y en Colombia. Las etapas anteriores construyeron los datos tratados (Etapa 3), el conocimiento evidente (Etapa 4) y el análisis multidimensional con modelo estrella (Etapa 5). Esta etapa busca **conocimiento oculto**: patrones que no se ven en un tablero ni en una consulta OLAP y que se obtienen con técnicas de minería de datos en **Orange Data Mining** (versión 3.40.0, según el aviso de actualización que muestra el programa).

Se desarrollan tres frentes: (A) tres modelos supervisados que predicen si un país tendrá un «gran evento» de desplazamiento; (B) un agrupamiento no supervisado de países según su perfil de desplazamiento; y (C) el análisis de texto de comentarios de YouTube sobre el tema, para contrastar los datos oficiales con la conversación pública. Al final se integran las conclusiones separando lo que respalda la evidencia de lo que solo es hipótesis, y se declaran con franqueza los pasos que quedaron fuera.

2. Datos y transformaciones

Conjunto	Origen	Unidad y tamaño	Transformaciones
`supervisado_gran_evento.csv` (parte A)	IDMC — GIDD, flujo anual de nuevos desplazamientos por país y causa, 2009–2024 (dataset tratado de la Etapa 3)	País–año–causa: 1.816 filas; **529 «Si»** (29,1 %) y 1.287 «No»	Se construyó la variable objetivo `gran_evento` (Si = 100.000 o más nuevos desplazamientos en ese año) y variables predictoras con información **solo de años anteriores** (flujo y stock previos, flujo medio y máximo previos, años previos con registro) en escala logarítmica. Se parte de 2009 porque 2008 no trae datos de conflicto.
`clustering_paises.csv` (parte B)	IDMC — GIDD (flujos 2017–2024) y SADD (stock 2024, «Ambos sexos»)	116 países (los que tienen stock SADD 2024)	Variables: flujo por conflicto, flujo por desastres, stock 2024 y % de menores. En Orange: logaritmo log(x+1) en las tres variables de volumen y estandarización ($\mu = 0$, $\sigma = 1$) de las cuatro. No se usa `gran_evento`.
`comentarios_youtube.csv` (parte C)	YouTube Data API v3	133 comentarios de primer nivel; 126 tras la limpieza	Quitar 2 vacíos y 5 duplicados exactos; minúsculas, sin acentos y stopwords en español (ver sección 6).

Nota sobre la transformación logarítmica del clustering. En Orange 3.40 no se encontró el widget *Feature Constructor* en el buscador, por lo que las tres columnas `log_conflicto`, `log_desastres` y `log_stock` (log(x+1)) se calcularon antes con un script y se cargaron en el archivo `clustering_paises_log.csv`; la estandarización sí se hizo dentro de Orange con el widget *Preprocess*. Las tres columnas originales sin logaritmo se marcaron como «skip».

3. Flujos de trabajo en Orange

Los tres flujos se guardaron en un único archivo, `etapa6_orange.ows` (repositorio, carpeta `etapa6/orange/`). Los diagramas de esta sección se generaron **a partir de las conexiones reales del archivo** (los widgets y canales que contiene), y las capturas de cada resultado se muestran en las secciones siguientes.

Widget	Parámetros usados (leídos del archivo .ows)
File (parte A)	Rol de `gran_evento` = target (Si/No); `iso3` y `pais` = meta
Tree	Mínimo de instancias por hoja = 5; no dividir subconjuntos menores de 10; profundidad máxima = 5; árboles binarios; «Stop when majority reaches» activo
Random Forest	**5 árboles**; máx. 5 atributos por división; no dividir subconjuntos menores de 5; **profundidad máxima 3**
Logistic Regression	Regularización Ridge (L2), C = 1
Test and Score	Validación cruzada de 10 particiones estratificada; clase objetivo «Si». Segundo widget: «Test on test data»
Select Rows (×2)	`anio` ≤ 2020 (entrenamiento, 1.180 filas) y `anio` > 2020 (prueba, 636 filas)
Preprocess (parte B)	Normalize Features → Standardize to μ = 0, σ = 1
k-Means	k de 2 a 8 (silhouette), inicialización k-means++, 10 re-ejecuciones, 300 iteraciones, sin normalizar (ya estandarizado)
Corpus / Unique / Select Rows	Corpus con la columna `texto`; Unique sobre `texto`; Select Rows con `texto` «is defined»
Preprocess Text	Transformación: minúsculas y quitar acentos; filtrado: stopwords en español
Bag of Words / Topic Modelling	Conteo de términos; Latent Dirichlet Allocation con 4 temas

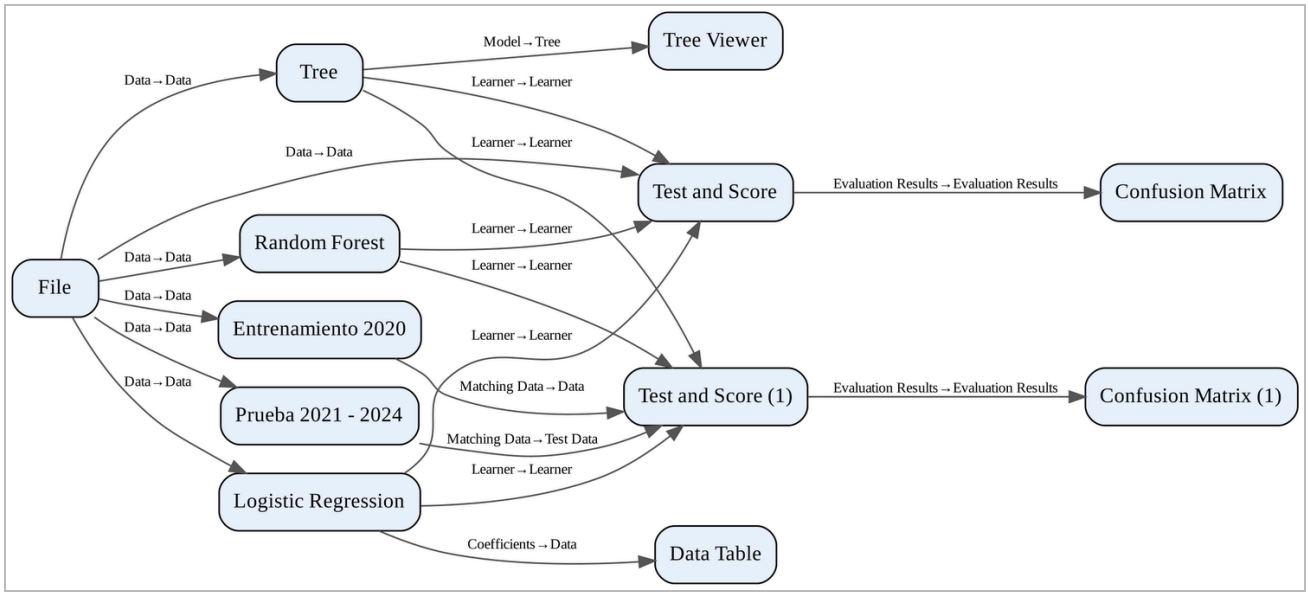


Figura 1. Flujo de la parte A (modelos supervisados y prueba hacia adelante), generado desde `etapa6_orange.ows`.

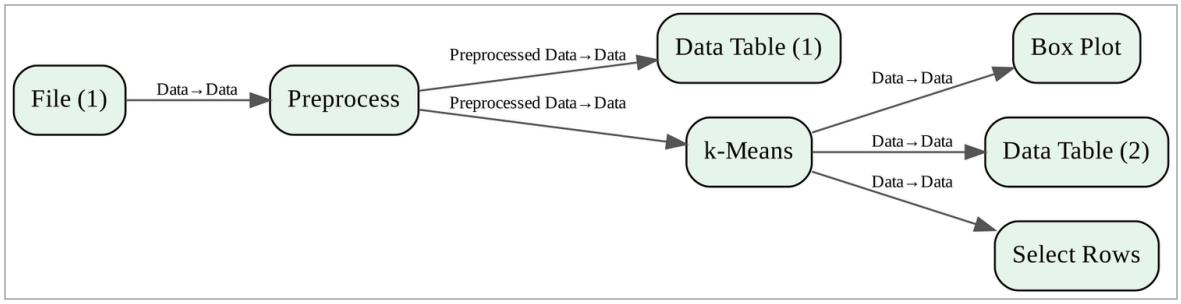


Figura 2. Flujo de la parte B (clustering), generado desde `etapa6_orange.ows`.

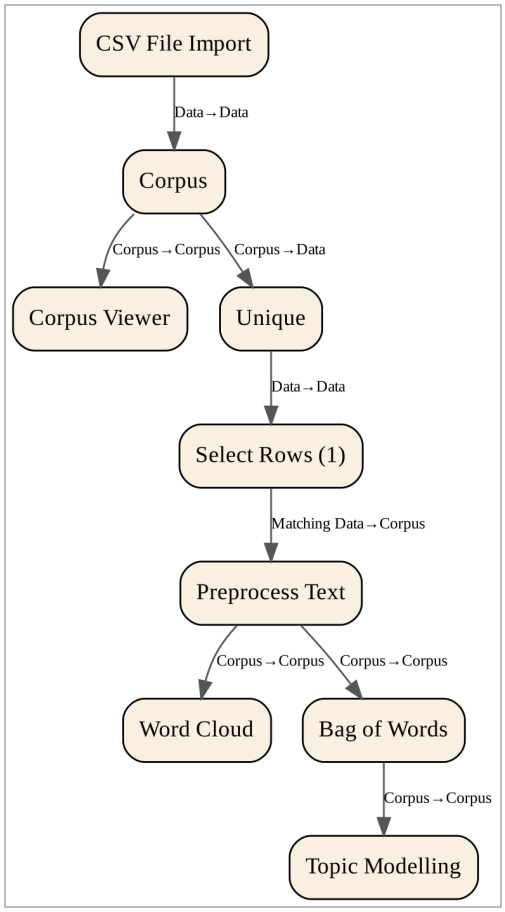


Figura 3. Flujo de la parte C (texto de YouTube), generado desde `etapa6_orange.ows`.

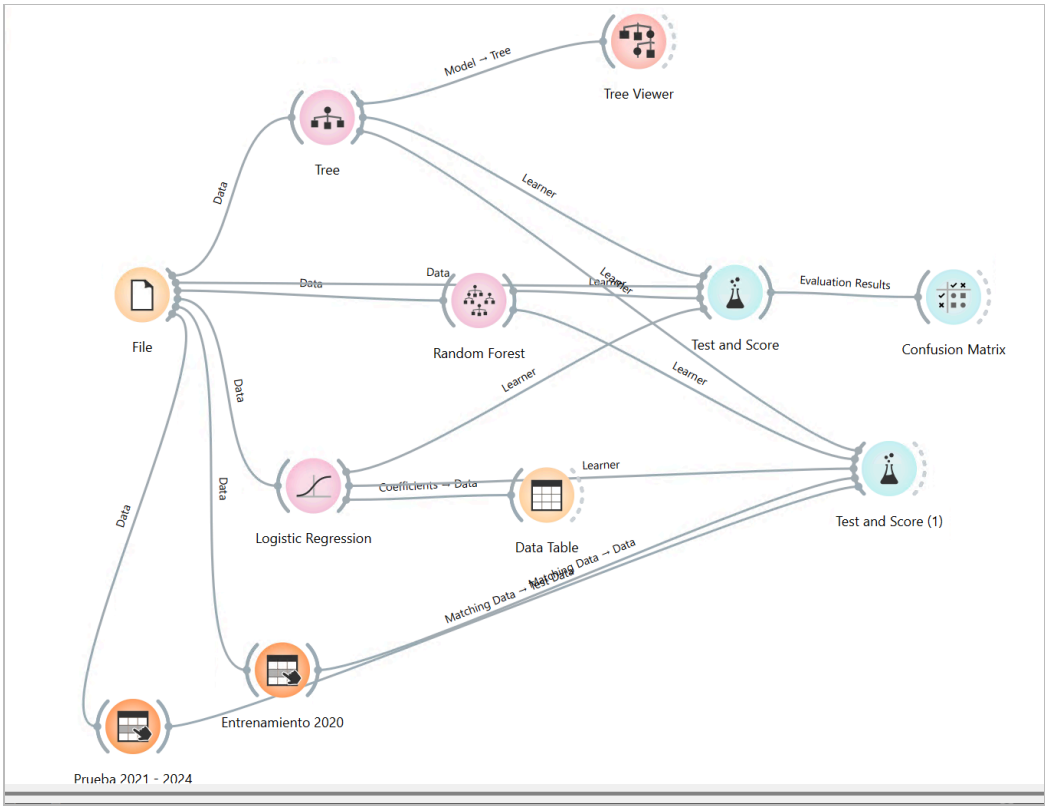


Figura 4. Captura del lienzo de Orange con el flujo supervisado y la prueba hacia adelante.

4. Parte A — Tres modelos supervisados

4.1 Pregunta, objetivo y tipo de problema

Pregunta: ¿un país superará los 100.000 nuevos desplazamientos (por conflicto o por desastres) en un año, a partir de su historial previo? **Variable objetivo:** `gran_evento` (Si/No). **Tipo: clasificación binaria**, no regresión, porque lo que se decide es si se supera un umbral y no el número exacto de desplazados. **Predictoras:** `causa`, `anio`, `log_flujo_anio_previo`, `log_stock_anio_previo`, `log_flujo_medio_previo`, `log_max_previo` y `anios_previos_con_registro`; todas usan solo años anteriores, de modo que la variable objetivo no se filtra a las predictoras.

Desbalance de clases. 71 % de los casos son «No». Un modelo que respondiera siempre «No» tendría 71 % de exactitud y recall 0 para «Si», así que la exactitud sola engaña. Por eso se reportan precisión, recall, F1 y MCC de la clase «Si» y se leen las matrices de confusión. Se evalúa el costo de errar: no anticipar un gran evento (falso negativo) cuesta más, en términos humanitarios, que una falsa alarma, por lo que el recall pesa más que la precisión.

4.2 Validación y métricas (la misma para los tres modelos)

Los tres modelos se entrenaron con los mismos datos y se compararon con el **mismo esquema**: validación cruzada de 10 particiones estratificada, clase objetivo «Si», en un único widget *Test and Score*.

Modelo	AUC	Exactitud	F1	Precisión	Recall	MCC
Tree	0,869	0,850	0,719	0,788	0,662	0,622
Random Forest (5 árboles, prof. 3)	0,880	0,842	0,713	0,756	0,675	0,607
Regresión logística (Ridge, C = 1)	**0,901**	**0,851**	**0,731**	0,773	**0,694**	**0,630**

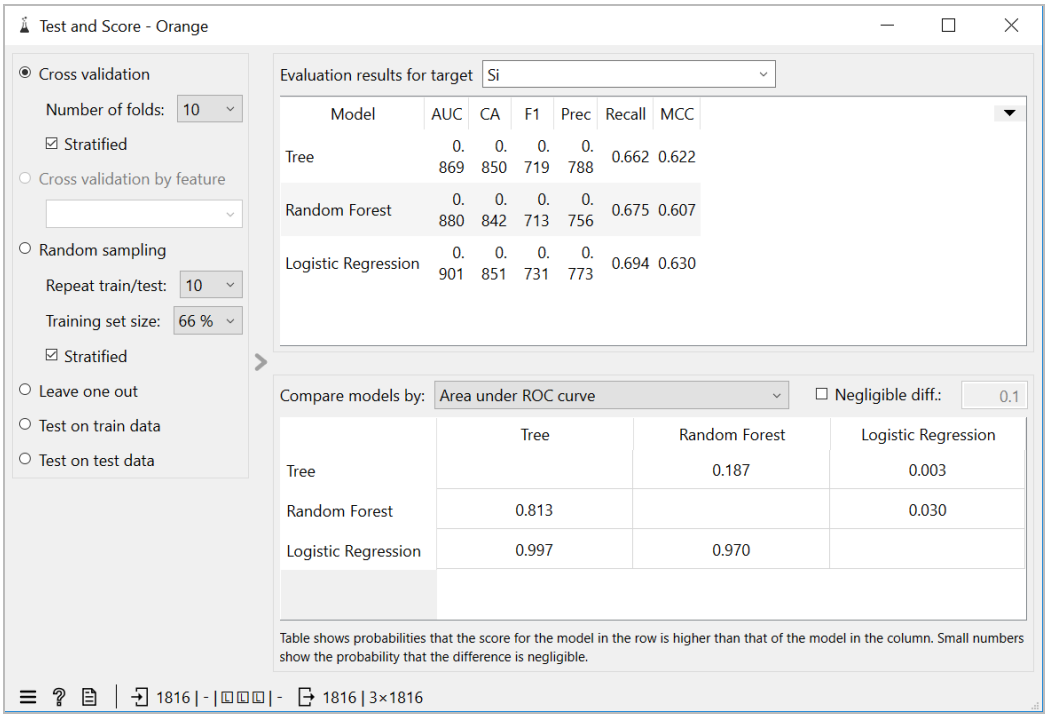


Figura 5. Test and Score: validación cruzada de 10 particiones, clase objetivo «Si». La tabla inferior da la probabilidad de que el AUC del modelo de la fila supere al de la columna: regresión logística frente a Tree 0,997 y frente a Random Forest 0,970.

4.3 Matrices de confusión (validación cruzada, n = 1.816; 529 «Si»)

Modelo	Verdaderos No	Falsas alarmas	Falsos negativos	Verdaderos Si
Tree	1.193	94	179	350
Random Forest	1.172	115	172	357
Regresión logística	1.179	108	**162**	**367**

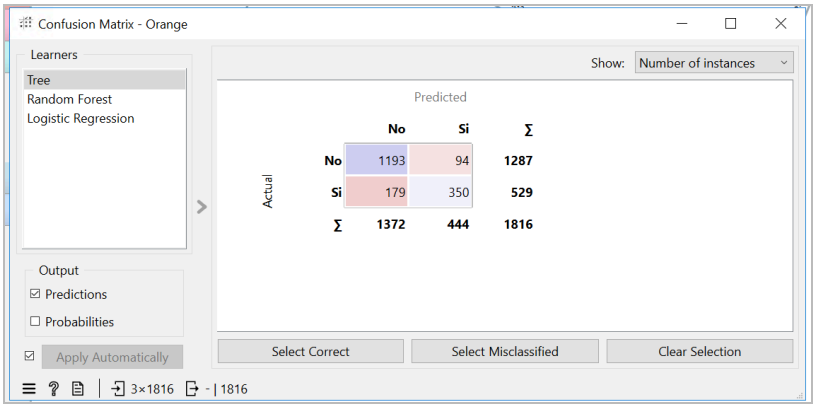


Figura 6. Matriz de confusión del Tree (validación cruzada).

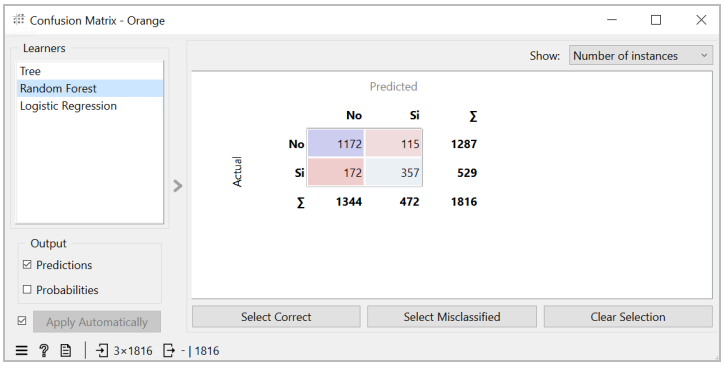


Figura 7. Matriz de confusión del Random Forest (validación cruzada).

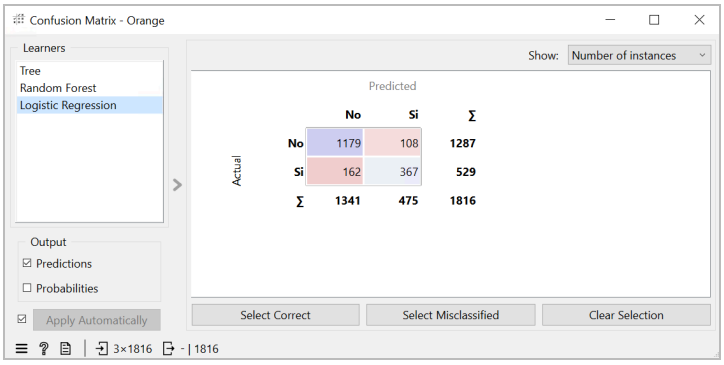


Figura 8. Matriz de confusión de la regresión logística (validación cruzada).

4.4 Prueba hacia adelante (entrenar con el pasado, evaluar con el futuro)

Para saber si el modelo funciona hacia adelante, se entrenó con los años ≤ 2020 (1.180 filas) y se evaluó con 2021–2024 (636 filas; 181 «Si» = 28,5 % y 455 «No»), con el widget *Test and Score* en modo «Test on test data». Predecir siempre «No» daría 71,5 % de exactitud en este conjunto.

Modelo	AUC	Exactitud	F1	Precisión	Recall	MCC
Tree	0,864	0,849	0,719	0,764	0,680	0,619
Random Forest	0,879	0,855	0,720	**0,803**	0,652	0,630
Regresión logística	**0,921**	**0,863**	**0,752**	0,776	**0,729**	**0,658**

Modelo	Verdaderos No	Falsas alarmas	Falsos negativos	Verdaderos Si
Tree	417	38	58	123
Random Forest	426	29	63	118
Regresión logística	417	38	**49**	**132**

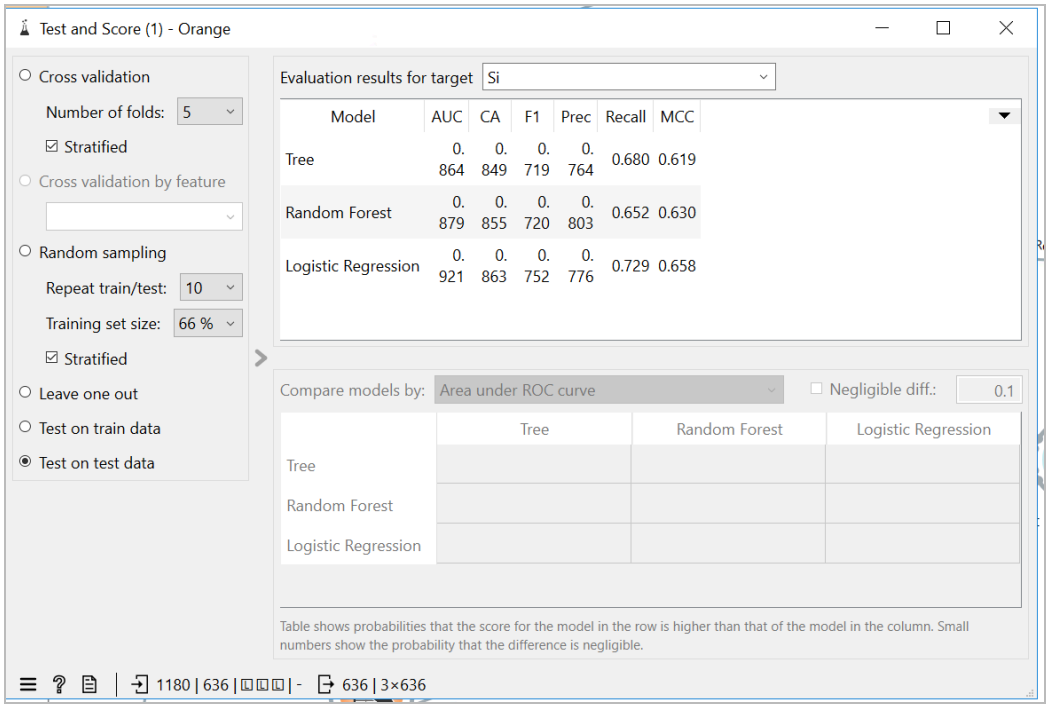


Figura 9. Prueba hacia adelante: métricas con entrenamiento ≤ 2020 y prueba 2021–2024 (1.180 | 636).

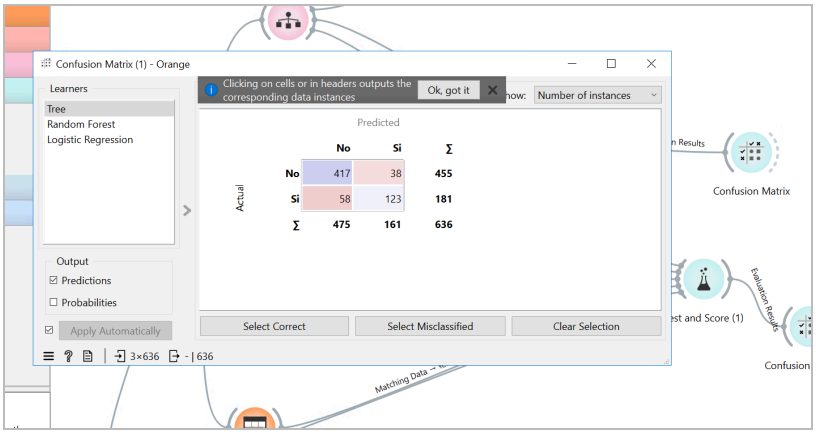


Figura 10. Matriz de confusión del Tree en la prueba hacia adelante.

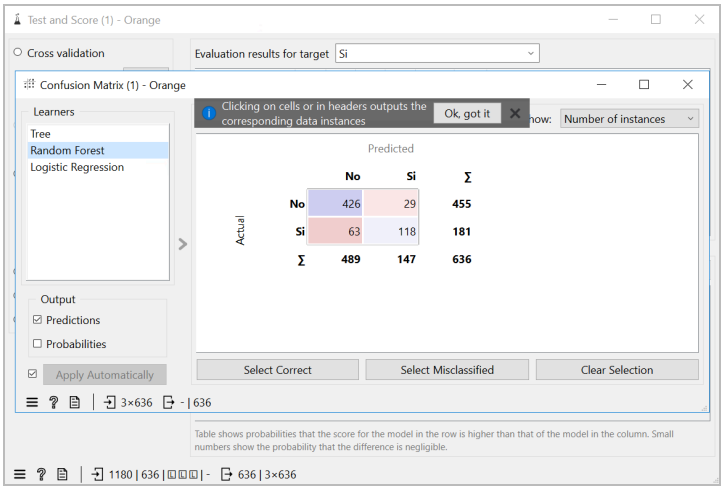


Figura 11. Matriz de confusión del Random Forest en la prueba hacia adelante.

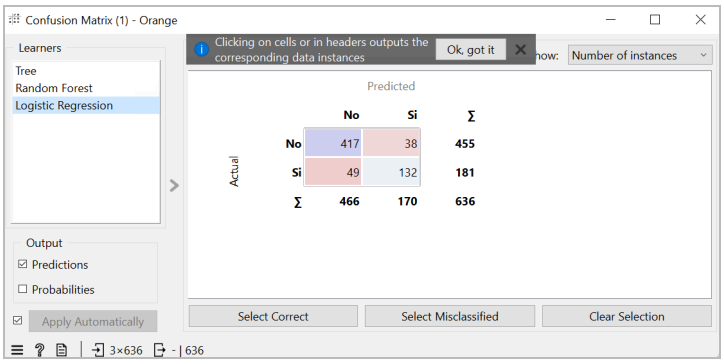


Figura 12. Matriz de confusión de la regresión logística en la prueba hacia adelante.

Lectura. Las métricas en la prueba hacia adelante son iguales o ligeramente mejores que en la validación cruzada (la regresión logística pasa de AUC 0,901 a 0,921 y de recall 0,694 a 0,729). No hay señal de que el modelo se degrade al predecir años posteriores a su entrenamiento, al menos con este corte (2020/2021). La mejora puede deberse en parte a diferencias en el balance de clases entre periodos, y no debe leerse como que el modelo mejora con el tiempo.

Incidente de documentación. Una primera ejecución de la prueba hacia adelante se hizo con solo 154 filas de entrenamiento por un filtro mal configurado. Se detectó porque el pie del widget decía 154 | 636 y no 1.180 | 636; se corrigió el filtro y esa ejecución se descartó. Las cifras de esta sección son las de la ejecución corregida.

4.5 Interpretación de la regresión logística

Variable	Coeficiente (clase «Si»)
intercepto	0,0026
causa = Conflicto…	+0,2657
causa = Desastres…	−0,2632
anio	−0,0053
log_flujo_anio_previo	+0,3518
log_stock_anio_previo	+0,0173
log_flujo_medio_previo	**+1,4396**
log_max_previo	−0,8632
anios_previos_con_registro	+0,0926

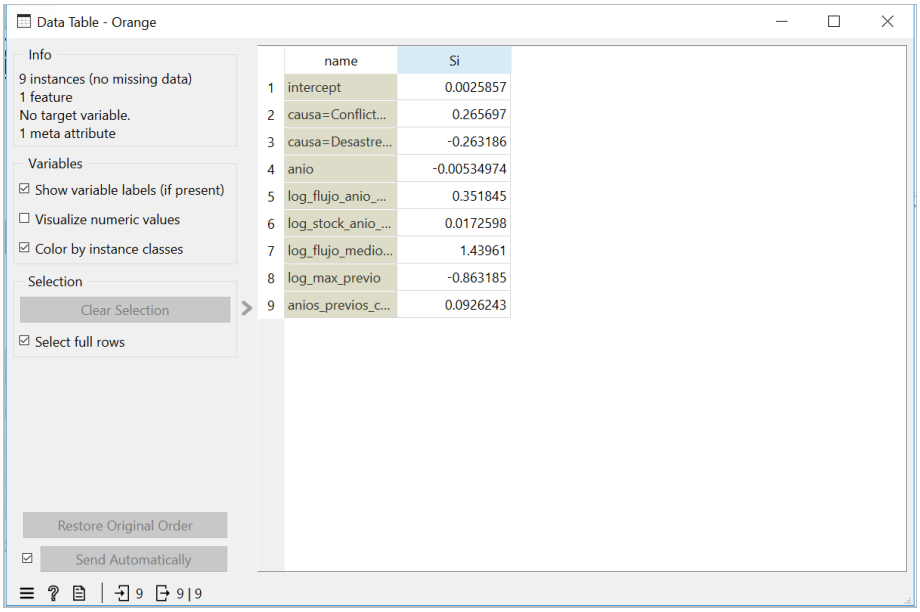


Figura 13. Coeficientes de la regresión logística (salida «Coefficients» del widget, Data Table).

La variable más influyente es el **flujo medio previo** del país: a mayor desplazamiento promedio en años anteriores, mayor probabilidad de un gran evento. La causa «conflicto» empuja la probabilidad hacia arriba y «desastres» hacia abajo en magnitud similar. El signo negativo del máximo previo no debe leerse como un efecto real: el flujo medio y el máximo previos están fuertemente relacionados entre sí (colinealidad), y la regularización reparte el efecto entre ambos. Los coeficientes se interpretan por su signo y su orden de magnitud relativo, no como efectos causales.

4.6 Selección del modelo

Se elige la regresión logística. Tiene el mejor AUC, F1, recall y MCC tanto en validación cruzada como en la prueba hacia adelante; encuentra más grandes eventos reales (367 de 529 en validación cruzada; 132 de 181 en la prueba hacia adelante) con una cantidad similar de falsas alarmas que el árbol; y es la más interpretable gracias a sus coeficientes. El Random Forest tiene la mayor precisión en la prueba hacia adelante (0,803) pero también el menor recall (0,652), lo que lo hace menos adecuado cuando perder un evento es más costoso. **Salvedad:** el Random Forest se configuró con solo 5 árboles y profundidad máxima 3, una configuración limitada; con más árboles y mayor profundidad podría acercarse a la regresión logística, por lo que la comparación no es concluyente para ese modelo.

Limitaciones. Pocas variables; una sola fuente por país-año; el modelo necesita historial previo y no sirve para países sin datos; la prueba hacia adelante usa un solo corte temporal; la causa no explica *por qué* ocurre el evento. El widget *Tree Viewer* no mostró el árbol («No tree») pese a que el árbol se entrenó y evaluó correctamente, por lo que no se incluyen las reglas del árbol.

5. Parte B — Clustering de países

5.1 Pregunta, variables y preparación

Pregunta: ¿qué perfiles de país se distinguen por su desplazamiento reciente (2017–2024), sin usar ninguna variable objetivo? **Variables:** `log_conflicto`, `log_desastres`, `log_stock` y `pct_menores_2024` (116 países, sin valores faltantes). **Normalización:** las variables de volumen tienen colas extremas (millones frente a miles), por lo que se aplicó logaritmo y luego estandarización; sin esto, pocos países grandes dominarían los grupos. **No se usa** `gran_evento`, la variable objetivo de la parte A, por lo que el agrupamiento no depende del modelo supervisado.

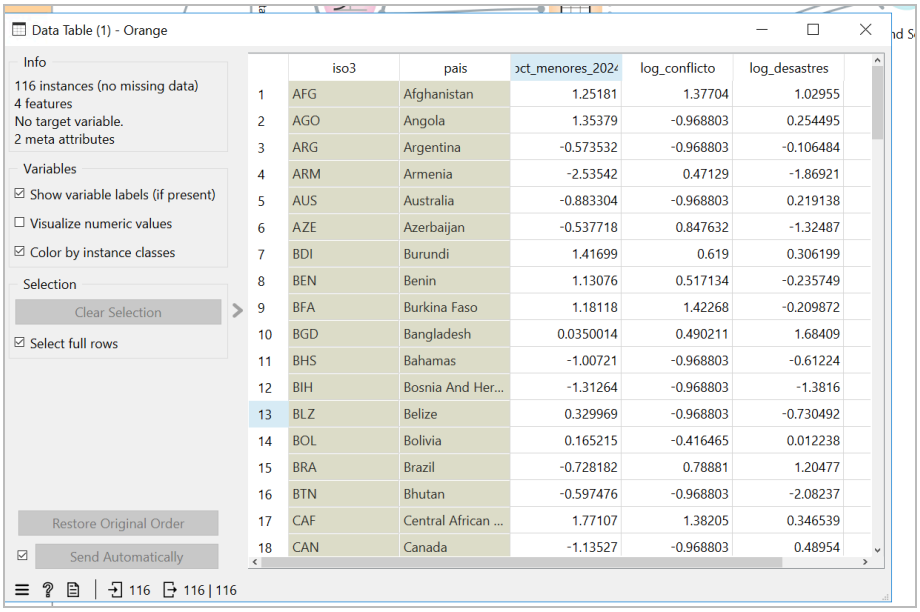


Figura 14. Datos estandarizados (salida de Preprocess): 116 instancias, 4 variables y 2 meta (`iso3`, `pais`), sin valores faltantes.

5.2 Algoritmo y elección de k

Se usó **k-Means** (inicialización k-means++, 10 re-ejecuciones, 300 iteraciones) con k de 2 a 8 y el criterio **silhouette**:

k	2	3	4	5	6	7	8
Silhouette	**0,382**	0,285	0,270	0,250	0,274	0,299	0,315

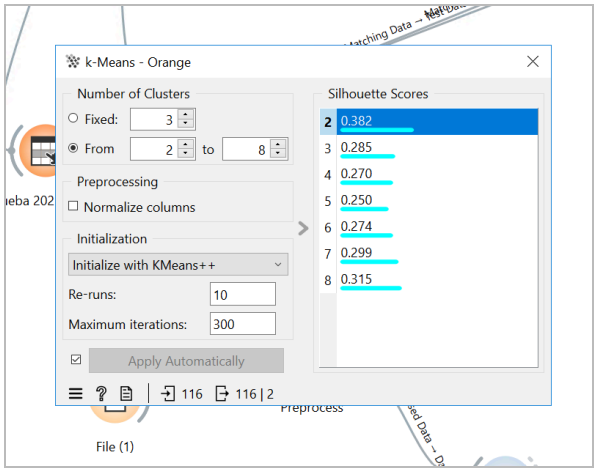


Figura 15. k-Means: puntaje de silhouette para k = 2 a 8.

Se elige **k = 2**: es el valor con mayor silhouette y los dos grupos son interpretables (apartado 5.3). Todos los puntajes son menores que 0,5, lo que indica una estructura de grupos **débil**: los países forman más bien un continuo que grupos nítidos, y algunos están cerca de la frontera entre los dos. Con k mayores el silhouette no mejora de forma sostenida (vuelve a subir de 0,250 en k = 5 a 0,315 en k = 8, sin superar el de k = 2).

5.3 Caracterización de los grupos

Variable (media estandarizada)	C1 (58 países)	C2 (58 países)	Estadístico t de Student
log_conflicto	−0,83	**+0,83**	15,98
log_stock	−0,78	**+0,78**	13,63
pct_menores_2024	−0,52	**+0,52**	6,58
log_desastres	−0,48	**+0,48**	5,82

Los dos grupos tienen 58 países cada uno (widget Select Rows sobre `Cluster`). La variable que más los separa es el flujo por conflicto, seguida del stock de desplazados. Los valores t y p describen **cuánto se separan** los grupos y no son una prueba de hipótesis, porque los grupos se formaron con esas mismas variables.

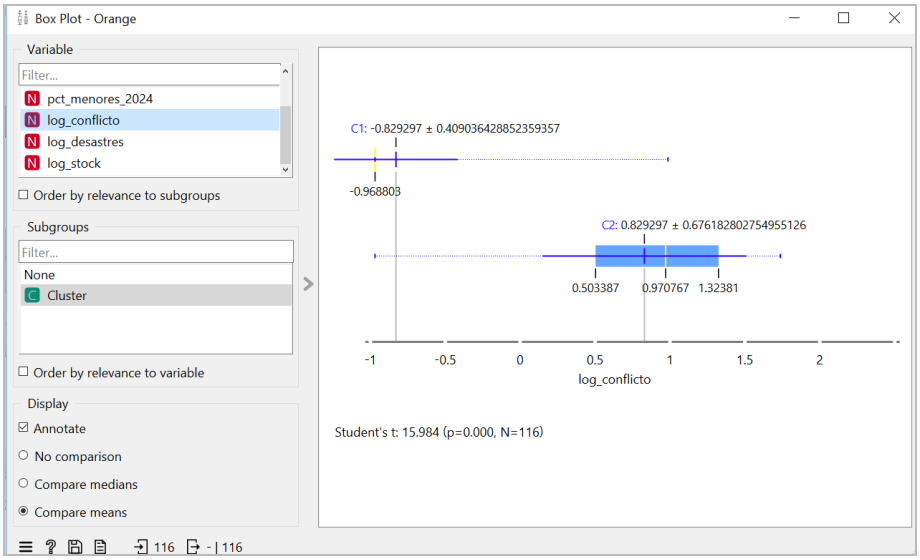


Figura 16. Box Plot de `log_conflicto` por grupo. En C1 la mediana es −0,969, que equivale a cero desplazamientos por conflicto.

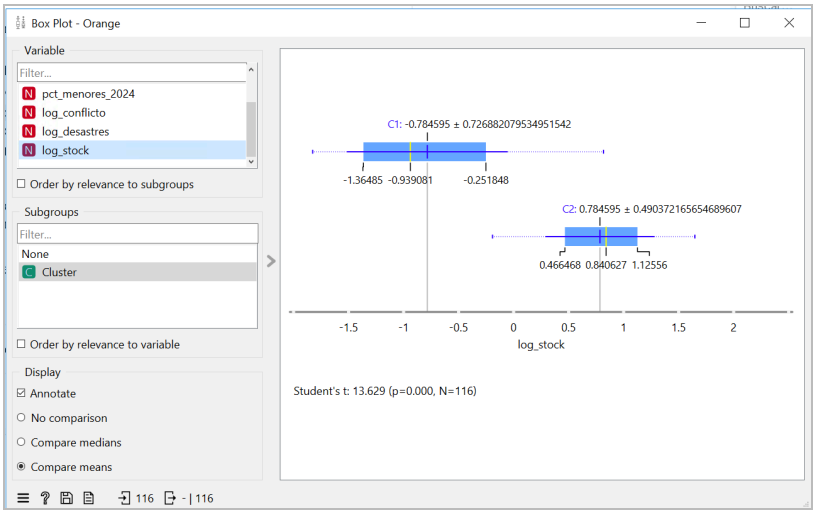


Figura 17. Box Plot de `log_stock` por grupo.

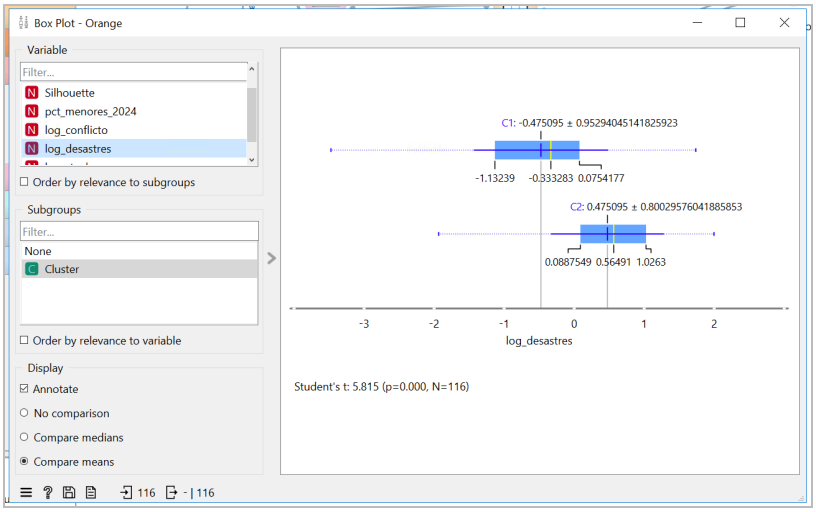


Figura 18. Box Plot de `log_desastres` por grupo.

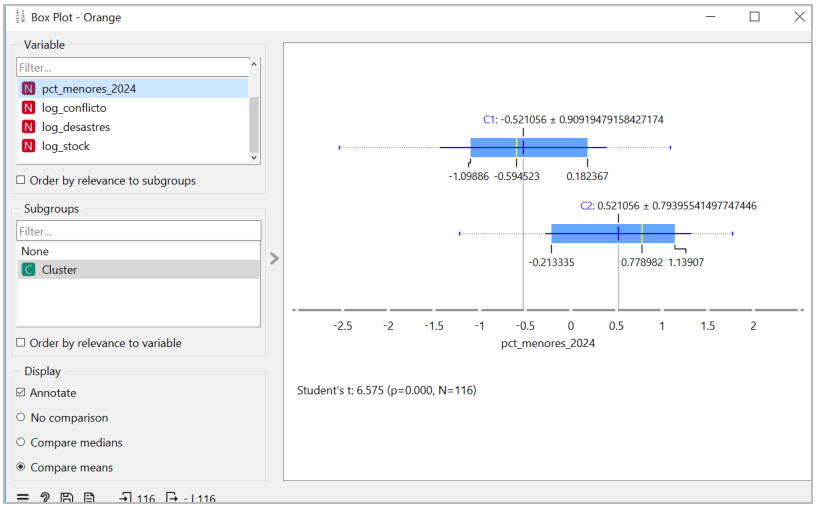
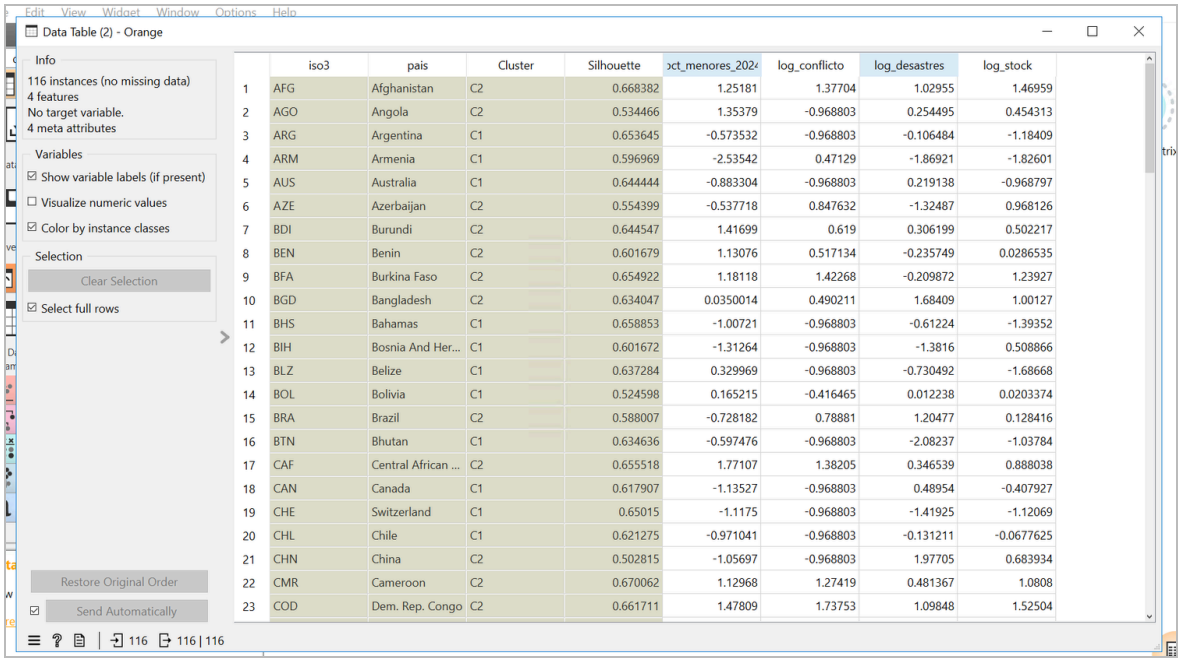


Figura 19. Box Plot de `pct_menores_2024` por grupo.



	iso3	pais	Cluster	Silhouette	...ct_menores_202...	log_conflicto	log_desastres	log_stock
1	AFG	Afghanistan	C2	0.668382	1.25181	1.37704	1.02955	1.46959
2	AGO	Angola	C2	0.534466	1.35379	-0.968803	0.254495	0.454313
3	ARG	Argentina	C1	0.653645	-0.573532	-0.968803	-0.106484	-1.18409
4	ARM	Armenia	C1	0.596969	-2.53542	0.47129	-1.86921	-1.82601
5	AUS	Australia	C1	0.644444	-0.883304	-0.968803	0.219138	-0.968797
6	AZE	Azerbaijan	C2	0.554399	-0.537718	0.847632	-1.32487	0.968126
7	BDI	Burundi	C2	0.644547	1.41699	0.619	0.306199	0.502217
8	BEN	Benin	C2	0.601679	1.13076	0.517134	-0.235749	0.0286535
9	BFA	Burkina Faso	C2	0.654922	1.18118	1.42268	-0.209872	1.23927
10	BGD	Bangladesh	C2	0.634047	0.0350014	0.490211	1.68409	1.00127
11	BHS	Bahamas	C1	0.658853	-1.00721	-0.968803	-0.61224	-1.39352
12	BIH	Bosnia And Her...	C1	0.601672	-1.31264	-0.968803	-1.3816	0.508866
13	BLZ	Belize	C1	0.637284	0.329969	-0.968803	-0.730492	-1.68668
14	BOL	Bolivia	C1	0.524598	0.165215	-0.416465	0.012238	0.0203374
15	BRA	Brazil	C2	0.588007	-0.728182	0.78881	1.20477	0.128416
16	BTN	Bhutan	C1	0.634636	-0.597476	-0.968803	-2.08237	-1.03784
17	CAF	Central African ...	C2	0.655518	1.77107	1.38205	0.346539	0.888038
18	CAN	Canada	C1	0.617907	-1.13527	-0.968803	0.48954	-0.407927
19	CHE	Switzerland	C1	0.65015	-1.1175	-0.968803	-1.41925	-1.12069
20	CHL	Chile	C1	0.621275	-0.971041	-0.968803	-0.131211	-0.0677625
21	CHN	China	C2	0.502815	-1.05697	-0.968803	1.97705	0.683934
22	CMR	Cameroon	C2	0.670062	1.12968	1.27419	0.481367	1.0808
23	COD	Dem. Rep. Congo	C2	0.661711	1.47809	1.73753	1.09848	1.52504

Figura 20. Data Table con cada país, su grupo (Cluster) y su silhouette individual (0,50 a 0,67 en las filas visibles).

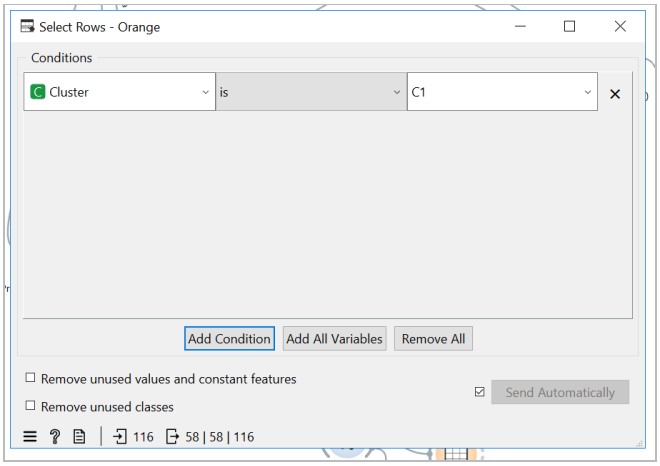


Figura 21. Select Rows con Cluster = C1: 58 países.

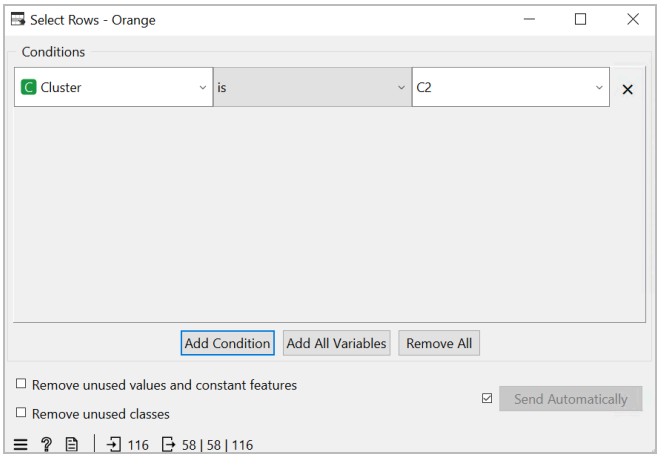


Figura 22. Select Rows con Cluster = C2: 58 países.

Grupo	Etiqueta	Qué lo distingue	Países de ejemplo (de la tabla)
C1 (58)	**Bajo desplazamiento**	Poco o ningún desplazamiento por conflicto (mediana equivalente a cero), menor stock de desplazados, menos desastres y menor proporción de menores	Argentina, Armenia, Australia, Bahamas, Bosnia y Herzegovina, Belice, Bolivia, Bután, Canadá, Suiza, Chile
C2 (58)	**Desplazamiento alto y multicausal**	Más desplazamiento por conflicto y también mayor stock, más desastres y mayor proporción de menores	Afganistán, Burkina Faso, Burundi, Rep. Centroafricana, Camerún, RD Congo, Bangladesh, Brasil; también Angola y China, que están en C2 por desastres y stock, sin desplazamiento por conflicto

Para qué sirve. Separar los países en dos perfiles permite diferenciar los mecanismos de respuesta: en C2 se combinan conflicto prolongado, grandes stocks de desplazados internos y mayor presencia de menores, con necesidades de protección y atención a largo plazo; en C1 predomina el riesgo bajo o episódico. Dentro de C2 hay países que están por desastres y no por conflicto (Angola, China), lo que muestra que dos grupos son una simplificación.

Contraste fuera de Orange (no es evidencia de Orange). Como referencia se exploró con scikit-learn un agrupamiento con k = 4 (silhouette 0,270), que separa perfiles más finos: crisis mayores por conflicto y desastres (36 países, p. ej. Sudán, Siria, Colombia, RD Congo, Afganistán), conflicto puntual con stock moderado (17), principalmente desastres (34) y bajo desplazamiento (29). No se ejecutó en Orange ni se usa como conclusión; se menciona como una dirección para afinar el análisis. No se ejecutó el clustering jerárquico ni el Silhouette Plot.

6. Parte C — Comentarios de YouTube

6.1 Propósito, fuente y procedimiento de extracción

Propósito. Los datos de las etapas anteriores son estadísticas oficiales (IDMC y CNMH). Los comentarios aportan **información nueva**: cómo habla el público de la migración y el desplazamiento, con qué palabras y con qué enfoque. No miden desplazamiento, sino percepción.

Aspecto	Detalle
Video	«Desplazamiento humano» — `https://www.youtube.com/watch?v=C8Rl59OtF6o` (fuente registrada por el autor; ver nota de verificación)
Fecha de extracción	5 de noviembre de 2026
Método	YouTube Data API v3, endpoint `commentThreads`, solo comentarios de primer nivel (sin respuestas), orden por fecha, límite de 500
Campos guardados	`texto`, `fecha` y `likes`. No se guarda el autor ni ningún dato personal
Cantidad	133 comentarios extraídos (el video tenía menos del límite de 500); 126 tras la limpieza
Rango de fechas	30 de mayo de 2022 a 23 de septiembre de 2026
Criterio de selección	Video sobre desplazamiento humano y migración, elegido por el autor por su relación directa con el tema del proyecto
Restricciones	Cuota diaria de la API; solo comentarios de primer nivel; no incluye comentarios eliminados o no visibles; la clave de API se lee de una variable de entorno y no se publica
Código	`etapa6/youtube/extraer_comentarios_youtube.py` (sin credenciales; el id del video se pasa como parámetro)

Nota de verificación. El código original recuperado del cuaderno de Colab tenía fijo otro identificador de video (`rWWBFxzrEdk`). No fue posible comprobar desde el entorno de trabajo cuál de los dos videos corresponde a los comentarios. Se registra como fuente el video indicado por el autor y se declara esta discrepancia como limitación de

trazabilidad. La clave de API usada en el cuaderno quedó expuesta en una conversación de trabajo y fue revocada; no aparece en el repositorio ni en este informe.

6.2 Limpieza y decisiones

Paso	Widget / criterio	Resultado
Carga	Corpus con `texto` como campo de texto	133 documentos
Duplicados	Unique sobre `texto`	5 duplicados exactos
Vacíos	Select Rows: `texto` «is defined»	2 vacíos; quedan **126** comentarios
Idioma	Mayoría en español; hay comentarios en inglés (p. ej. «migration»)	Stopwords solo en español; el inglés quedó sin tratar
Ruido por contexto escolar	Conteo por palabras clave sobre el CSV (script)	37 de 126 mencionan tarea, examen, maestra, clase o colegio (29 %); se conservan y se tratan como un grupo propio

6.3 Flujo de texto en Orange y resultados

Preprocess Text (minúsculas, sin acentos, stopwords en español) → **Word Cloud** y **Bag of Words** (conteo) → **Topic Modelling** (LDA, 4 temas). El Word Cloud es solo un apoyo; el análisis de temas se hizo con el modelo LDA.

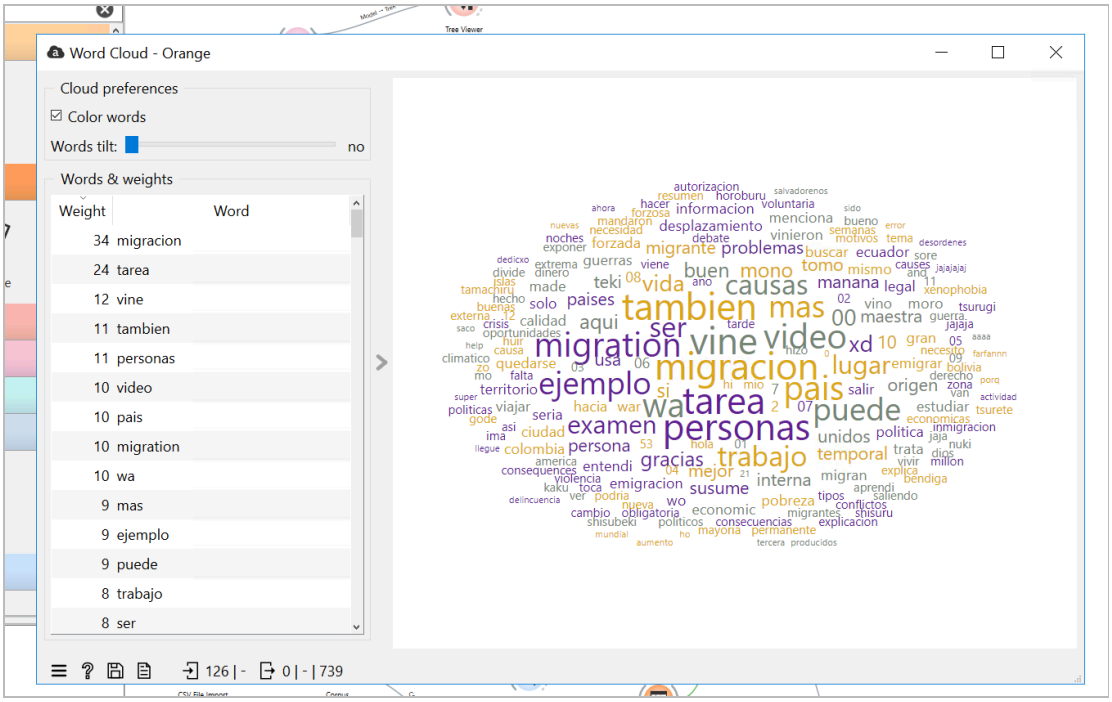


Figura 23. Word Cloud de los 126 comentarios. Pesos mayores: migracion 34, tarea 24, vine 12, tambien 11, personas 11, video 10, pais 10, migration 10, wa 10.

Ruido no filtrado. Se intentó añadir un filtro por expresión regular para quitar términos de ruido (números, risas, «xd», «wa», «tambien», «mas», «vine»), pero no quedó activo en el flujo guardado, que solo tiene el filtro de stopwords. Por eso esos términos aparecen en la nube y en un tema. Es una limitación del resultado, no un resultado sobre el tema.

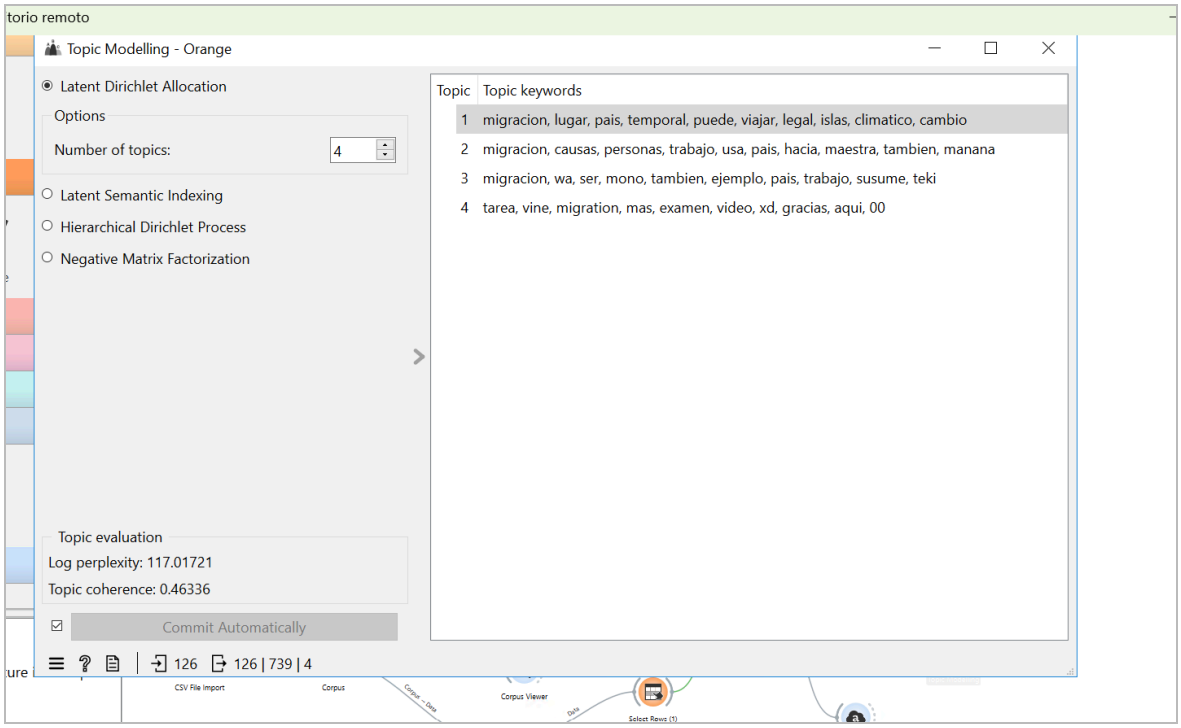


Figura 24. Topic Modelling (LDA, 4 temas): palabras principales de cada tema. Perplejidad logarítmica 117,0; coherencia 0,463.

Tema	Palabras principales	Lectura (hipótesis del autor)
1	migracion, lugar, pais, temporal, puede, viajar, legal, islas, climatico, cambio	Tipos y causas de la migración: temporal, legal, climática
2	migracion, causas, personas, trabajo, usa, pais, hacia, maestra, tambien, manana	Causas laborales y destino (Estados Unidos)
3	migracion, wa, ser, mono, tambien, ejemplo, pais, trabajo, susume, teki	Mezcla sin tema claro; contiene términos de ruido, probablemente comentarios fuera de tema
4	tarea, vine, migration, mas, examen, video, xd, gracias, aqui, 00	Comentarios de espectadores por tarea escolar

Para dimensionar el contenido, se contó (sobre los 126 comentarios, por palabras clave, no por clasificación manual) cuántos mencionan cada asunto:

Asunto (palabras clave)	Comentarios
Tarea, examen, maestra, clase, colegio	37
Migración / migrar / migrante	36
Economía, trabajo, pobreza, dinero	15
Guerra, conflicto, violencia	10
Estados Unidos (usa, eeuu)	7
«Forzado/forzosa»	6
«Desplazamiento»	4
Clima / desastre / natural	3
Colombia	3
Refugiado	1

Distribución por año de los 126 comentarios: 2022 (6), 2023 (35), 2024 (41), 2025 (32) y 2026 (12). 74 de ellos tienen al menos un «me gusta» (promedio 6,4; máximo 403).

6.4 Qué aporta frente a los datos originales y su alcance

Información nueva. Los datos oficiales dicen cuánta gente se desplaza y por qué causa. Los comentarios muestran que, en este video, la conversación gira en torno a la **migración en general** (causas económicas y laborales, destino en Estados Unidos) y mucho menos al desplazamiento forzado: «desplazamiento» aparece en 4 de 126 comentarios y «forzado/forzosa» en 6, frente a 36 que hablan de migración.

Representatividad. Son 126 comentarios de **un solo video**, escritos por quienes decidieron comentar; casi un tercio proviene de estudiantes con tareas. No representan a la población colombiana ni mundial. Con tan pocos textos, el modelo de temas es inestable y cambia entre ejecuciones; los temas y su lectura deben tomarse como exploratorios.

No ejecutado. Quedaron fuera de esta entrega: el análisis de sentimiento (*Sentiment Analysis*), los embeddings de documentos con clustering de comentarios, *Word Enrichment* y *Concordance*. Se declaran como trabajo pendiente y no se presentan resultados de ellos.

7. Conclusiones integradas

7.1 Respaldado por evidencia (cifras de Orange)

- **E1.** Es posible anticipar un gran evento de desplazamiento (100.000 o más) con el historial previo del país: AUC 0,901 en validación cruzada y 0,921 en la prueba hacia adelante con la regresión logística.
- **E2.** El desempeño se mantiene al predecir años posteriores al entrenamiento (2021–2024 entrenando con ≤ 2020); recall 0,729 y F1 0,752.
- **E3.** La regresión logística es el mejor modelo de los tres: mejor AUC, F1, recall y MCC; probabilidad de que supere al árbol 0,997 y al Random Forest 0,970 en AUC (validación cruzada).
- **E4.** El mejor predictor de un gran evento es el flujo medio previo del país (coeficiente +1,44), y el conflicto empuja la probabilidad al alza frente a los desastres.
- **E5.** Los 116 países se dividen en dos perfiles de 58: bajo desplazamiento (C1) y desplazamiento alto y multicausal (C2). El conflicto es la variable que más los separa (t = 15,98).
- **E6.** En los comentarios analizados predomina la migración en general sobre el desplazamiento forzado, y 37 de 126 provienen de contexto escolar.

7.2 Hipótesis (no comprobadas con estos datos)

- **H1.** El público confunde migración con desplazamiento forzado; solo se comprobó que el vocabulario de este video favorece la primera. No se puede extender a otros videos ni a la población.
- **H2.** Los países de C2 son los que necesitan respuestas humanitarias prolongadas, mientras que C1 requiere vigilancia de eventos puntuales. Es una lectura de los perfiles, no un resultado del modelo.
- **H3.** Un Random Forest mejor configurado (más árboles y profundidad) podría igualar o superar a la regresión logística.
- **H4.** Los temas de los comentarios (causas laborales, climáticas, tarea escolar) reflejan lo que piensa una parte del público, pero con 126 textos de un video no se puede afirmar.

7.3 Decisiones posibles

- **Alerta temprana:** usar la regresión logística, priorizando el recall, para marcar países con alta probabilidad de gran evento y revisar sus casos. Las falsas alarmas (38 de 455 en la prueba hacia adelante) son un costo aceptable frente a los 49 eventos no detectados.
- **Respuesta diferenciada por perfil de país** (C1 y C2), tomando en cuenta que C2 no es homogéneo.

- **Comunicación pública:** aclarar la diferencia entre migración y desplazamiento forzado, solo si estudios con más comentarios y más videos confirman la hipótesis H1.

8. Limitaciones generales

- El Random Forest se configuró con 5 árboles y profundidad 3; la comparación entre los tres modelos no es concluyente para ese modelo.
- El agrupamiento tiene silhouette bajo (0,382); las fronteras entre grupos no son nítidas, y los valores t describen la separación pero no prueban hipótesis.
- El filtro de ruido del texto no quedó activo, y no se ejecutaron sentimiento, embeddings, Word Enrichment ni Concordance.
- Los comentarios son de un solo video, pocos, y su fuente tiene una discrepancia documentada.
- El widget Tree Viewer no mostró el árbol y el widget Feature Constructor no estuvo disponible en la instalación usada; las columnas logarítmicas del clustering se calcularon fuera de Orange.
- Los datos de la parte A cubren 2009–2024 y requieren historial previo; no aplican a países sin datos.

9. Reproducibilidad y archivos del repositorio

Archivo (repositorio)	Contenido
`etapa6/orange/etapa6_orange.ows`	Los tres flujos de Orange (partes A, B y C)
`etapa6/datos/supervisado_gran_evento.csv`	Datos de la parte A (1.816 filas)
`etapa6/datos/clustering_paises.csv` y `clustering_paises_log.csv`	Datos de la parte B (116 países; el segundo incluye las columnas en logaritmo)
`etapa6/datos/comentarios_youtube.csv`	133 comentarios (126 tras la limpieza) con texto, fecha y likes; sin datos de autores
`etapa6/youtube/extraer_comentarios_youtube.py`	Script de extracción; usa la variable de entorno `YOUTUBE_API_KEY`
`etapa6/informe/Informe_Etapa6_Conocimiento_Oculto.pdf`	Este informe
`templates/conocimiento_oculto.html` y `app.py`	Sección «Conocimiento Oculto» de la aplicación Flask

Para reproducir: abrir `etapa6_orange.ows` en Orange 3.40 y, en cada widget File o CSV File Import, reemplazar la ruta del archivo por la copia local del CSV correspondiente. Todos los datos usados son públicos (IDMC) o comentarios sin datos personales. Los CSV de la parte A y B se derivan del dataset tratado de la Etapa 3 (ver sección 2).

10. Enlaces

Repositorio: https://github.com/DROMEROH14/migracion-desplazamiento-humano
Aplicación (sección «Conocimiento Oculto»): https://dromeroh14.pythonanywhere.com/conocimiento-oculto
Video de sustentación (máx. 10 min): [ENLACE DEL VIDEO PENDIENTE: se agrega al publicarlo]

11. Referencias

- Internal Displacement Monitoring Centre (IDMC). Global Internal Displacement Database (GIDD) y estimaciones por sexo y edad (SADD). https://www.internal-displacement.org/database
- Centro Nacional de Memoria Histórica (CNMH). Observatorio de memoria y conflicto: desplazamiento forzado.
- Demšar, J. et al. (2013). Orange: Data Mining Toolbox in Python. *Journal of Machine Learning Research*, 14, 2349–2353. Orange Data Mining: https://orangedatamining.com

- Google. YouTube Data API v3, recurso *commentThreads*. https://developers.google.com/youtube/v3/docs/commentThreads
- Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
- Blei, D., Ng, A. y Jordan, M. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022.